



Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP
Curso de

**Avaliação Comparativa de Arquiteturas RAG para Respostas
Jurídico-Administrativas Confiáveis:** recuperação densa, esparsa,
híbrida (denso-esparsa) e por grafo (GraphRAG) com geração
single-pass e multiagente no corpus jurídico-administrativo brasileiro

Pedro Ivo Guimarães Póvoa
Orientador: Prof. Dr. Alex Lopes Pereira

Brasília-DF
2026

PEDRO IVO GUIMARÃES PÓVOA

**Avaliação Comparativa de Arquiteturas RAG para Respostas
Jurídico-Administrativas Confiáveis:** recuperação densa, esparsa,
híbrida (denso-esparso) e por grafo (GraphRAG) com geração
single-pass e multiagente no corpus jurídico-administrativo brasileiro

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Orientador(a): Prof. Dr. Alex Lopes Pereira

Brasília-DF
2026

PÓVOA, Pedro Ivo Guimarães

Avaliação Comparativa de Arquiteturas RAG para Respostas Jurídico-Administrativas Confiáveis: recuperação densa, esparsa, híbrida (denso-esparsa) e por grafo (GraphRAG) com geração single-pass e multiagente no corpus jurídico-administrativo brasileiro / Pedro Ivo Guimarães Póvoa. – Brasília: IDP, 2026.

00 p.

Inclui bibliografia.

Trabalho de Conclusão de Curso (Dissertação) – Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, Curso de , Brasília, 2026.

Orientador: Prof. Dr. Alex Lopes Pereira.

1. Inteligência artificial. 2. Recuperação da informação. 3. Administração pública – Processamento de dados. I. Título.

CDD: XXX

Ficha catalográfica elaborada pela Biblioteca Ministro Moreira Alves
Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP

PEDRO IVO GUIMARÃES PÓVOA

**Avaliação Comparativa de Arquiteturas RAG para Respostas Jurídico-Administrativas
Confiáveis: recuperação densa, esparsa, híbrida (denso-esparso) e por grafo (GraphRAG)
com geração single-pass e multiagente no corpus jurídico-administrativo brasileiro**

Dissertação apresentada ao programa de pós-graduação em Administração Pública, como parte do requisito para a obtenção do título de Mestre em Administração Pública pelo Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP.

Orientador(a): Prof. Dr. Alex Lopes Pereira

Brasília, 3 de maio de 2027.

Banca Examinadora

Prof. Dr. Alex Lopes Pereira
Orientador

A definir
Examinador

A definir
Examinador

*Dedico aos meus pais, por todo amor, confiança
e apoio em toda a minha vida.
Dedico também a todos que estiveram comigo
durante a realização do meu curso.*

AGRADECIMENTOS

Agradeço à minha família, pelo apoio incondicional em todos os momentos desta caminhada.

Ao meu orientador, Prof. Dr. Alex Lopes Pereira, pela paciência, pela generosidade intelectual e pelo rigor com que conduziu a orientação deste trabalho.

Aos professores e servidores do Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa – IDP, pela formação recebida.

Aos colegas de turma, pelas discussões que ajudaram a amadurecer as ideias aqui apresentadas.

“A ciência é feita de dados como uma casa é feita de pedras. Mas um amontoado de dados não é ciência, assim como um monte de pedras não é uma casa.”

(POINCARÉ, 1902, p. 141)

RESUMO

Sistemas de *Retrieval-Augmented Generation* (RAG) dependem da qualidade da recuperação, e em corpus jurídico-administrativo brasileiro a busca vetorial pura falha na recuperação de termos exatos e em perguntas que conectam documentos distintos. Este trabalho compara empiricamente estratégias de recuperação — RAG denso, RAG denso-esparso e GraphRAG incremental, implementado sobre PostgreSQL com pgvector e Apache AGE em armazenamento único — e estratégias de geração — single-pass e verificada multiagente, no padrão Researcher-Auditor-Adjudicator — sobre um corpus de documentos normativos brasileiros — leis federais, resoluções do Conselho Nacional de Justiça e instruções normativas do Tribunal de Contas da União. A avaliação usa um golden dataset de perguntas intra e inter-documentos, as métricas RAGAS (Faithfulness, Context Precision, Context Recall e Answer Relevancy) e o teste de Wilcoxon signed-rank pareado com correção de Bonferroni. Na fase confirmatória, o GraphRAG incremental supera o RAG denso, mas não o RAG denso-esparso, e a geração multiagente não melhora a Faithfulness nem a taxa de verificação de citação em relação à single-pass: as hipóteses H1 e H2 não se confirmam. Uma fase exploratória ampliou a comparação para catorze condições de recuperação e mostrou que remover o reranking do RAG denso-esparso eleva a Context Precision sem perda nas demais métricas, e que a busca esparsa pura (BM25) alcança a maior Context Precision entre as condições formais. A configuração mais precisa encontrada combina RAG denso-esparso sem reranking com geração single-pass, mais simples e barata que a prevista nas hipóteses. O GraphRAG puro, que entrega ao gerador apenas descrições sintéticas de entidades, ficou abaixo das demais condições, e a explicação mais sustentada pelos dados é o descasamento entre esse formato e a métrica de Faithfulness. Entre as limitações do estudo estão o uso de um único juiz de LLM e uma métrica de recuperação baseada em identificador de trecho, e não em sobreposição de caracteres.

Palavras-chave: Recuperação Aumentada por Geração (RAG). GraphRAG. Grafos de Conhecimento. Geração Verificada. Corpus Jurídico-Administrativo.

ABSTRACT

Retrieval-Augmented Generation (RAG) systems depend on retrieval quality, and over Brazilian legal-administrative corpora, pure vector search fails at retrieving exact terms and at answering questions that connect distinct documents. This work empirically compares retrieval strategies — dense RAG, dense-sparse RAG and incremental GraphRAG, implemented on PostgreSQL with pgvector and Apache AGE as a single store — and generation strategies — single-pass and multi-agent verified generation, following the Researcher-Auditor-Adjudicator pattern — over a corpus of Brazilian normative documents: federal laws, resolutions of the National Council of Justice and normative instructions of the Federal Court of Accounts. The evaluation uses a golden dataset of intra- and cross-document questions, the RAGAS metrics (Faithfulness, Context Precision, Context Recall and Answer Relevancy) and the paired Wilcoxon signed-rank test with Bonferroni correction. In the confirmatory phase, incremental GraphRAG outperforms dense RAG but not dense-sparse RAG, and multi-agent generation improves neither Faithfulness nor the citation verification rate over single-pass generation: hypotheses H1 and H2 are not confirmed. An exploratory phase extended the comparison to fourteen retrieval conditions and showed that removing the reranking step from dense-sparse RAG raises Context Precision with no loss on the other metrics, and that pure sparse search (BM25) achieves the highest Context Precision among the formal conditions. The most precise configuration found combines dense-sparse RAG without reranking with single-pass generation, which is simpler and cheaper than the one the hypotheses predicted. Pure GraphRAG, which hands the generator only synthetic entity descriptions, performed below the other conditions, and the explanation best supported by the data is a mismatch between that format and the Faithfulness metric. Among the study’s limitations are the use of a single LLM judge and a retrieval metric based on chunk identifiers rather than character overlap.

Keywords: Retrieval-Augmented Generation (RAG). GraphRAG. Knowledge Graphs. Verified Generation. Legal-Administrative Corpus.

LISTA DE ILUSTRAÇÕES

Figura 1 – Esquema ilustrativo do pipeline de recuperação e geração avaliado	17
--	----

LISTA DE TABELAS

Tabela 1 – Condições de recuperação comparadas neste trabalho	18
---	----

LISTA DE QUADROS

LISTA DE GRÁFICOS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
CDD	Classificação Decimal de Dewey
DPP	Decanato de Pesquisa e Pós-Graduação
IDP	Instituto Brasileiro de Ensino, Desenvolvimento e Pesquisa
MEC	Ministério da Educação
RDs	Repositórios Digitais
TCC	Trabalho de Conclusão de Curso

SUMÁRIO

1	INTRODUÇÃO.....	15
1.1	Objetivo geral.....	15
1.2	Objetivos específicos	15
1.3	Problema	15
1.4	Hipótese.....	15
1.5	Justificativa	16
2	REFERENCIAL TEÓRICO	17
2.1	RAG: origem e evolução do paradigma	17
3	PROCEDIMENTOS METODOLÓGICOS	19
3.1	Tipo e abordagem da pesquisa	19
3.2	Instrumentos de coleta de dados	19
3.3	Procedimentos de análise.....	19
4	ANÁLISE E DISCUSSÃO DOS DADOS.....	20
4.1	Apresentação dos resultados	20
4.2	Discussão.....	20
5	CONSIDERAÇÕES FINAIS.....	21
	REFERÊNCIAS	22
	APÊNDICE A – Roteiro de entrevista semiestruturada.....	23
	APÊNDICE B – Tabelas complementares	24
	ANEXO A – Legislação de referência	25

1 INTRODUÇÃO

Sistemas de Retrieval-Augmented Generation (RAG) respondem perguntas combinando um modelo de linguagem com uma busca sobre uma base documental, o que reduz alucinação e permite atualizar o conhecimento do sistema sem retreinar o modelo (LEWIS *et al.*, 2020). Essa vantagem depende da qualidade da recuperação. Em corpus jurídico-administrativo brasileiro — leis federais, resoluções do Conselho Nacional de Justiça e instruções normativas do Tribunal de Contas da União —, a busca vetorial pura erra na recuperação de termos exatos (siglas, números de processo, remissões normativas) e não resolve perguntas que exigem conectar informação distribuída entre documentos distintos, como saber se uma norma continua em vigor diante de um ato que a revoga. O GraphRAG ataca essa segunda limitação complementando a busca vetorial com um grafo de conhecimento entre documentos (EDGE *et al.*, 2024), mas as implementações consolidadas reconstroem o grafo inteiro em lote, premissa incompatível com um acervo que cresce continuamente.

1.1 Objetivo geral

Comparar empiricamente, sobre um corpus jurídico-administrativo brasileiro em português, estratégias de recuperação de informação (RAG denso, RAG denso-esparso e GraphRAG incremental) e estratégias de geração de resposta (single-pass e verificada multiagente).

1.2 Objetivos específicos

- Objetivo específico 1;
- Objetivo específico 2;
- Objetivo específico 3.

1.3 Problema

Formule a questão problema em forma de pergunta, de modo claro e delimitado.

1.4 Hipótese

Apresente a resposta provisória que a pesquisa pretende confirmar ou refutar.

1.5 Justificativa

Explique a relevância acadêmica e social do tema e o que motivou a escolha do recorte adotado.

2 REFERENCIAL TEÓRICO

O método de condução desta revisão está descrito na Seção de procedimentos metodológicos. Este capítulo revisa a literatura que fundamenta cada decisão arquitetural do sistema avaliado neste trabalho, seguindo a ordem do próprio pipeline de processamento — da origem do paradigma de RAG à avaliação dos resultados. As seções seguintes situam a recuperação híbrida na evolução do RAG, posicionam a arquitetura de GraphRAG incremental adotada frente às variantes já publicadas e fecham o capítulo com a metodologia de avaliação e o posicionamento deste trabalho frente a pesquisas comparáveis.

2.1 RAG: origem e evolução do paradigma

O paradigma de Retrieval-Augmented Generation (RAG) combina um modelo de linguagem com um mecanismo de recuperação sobre uma base documental externa ao modelo — não aos parâmetros aprendidos durante o treinamento, mas a uma base consultada em tempo de inferência —, condicionando a geração da resposta ao conteúdo recuperado em vez de depender só do conhecimento implícito nos parâmetros (LEWIS *et al.*, 2020). A formulação original acopla um retriever denso (embeddings) a um gerador treinado conjuntamente, aplicado a tarefas intensivas em conhecimento como perguntas e respostas em domínio aberto.

Figura 1 – Esquema ilustrativo do pipeline de recuperação e geração avaliado



Fonte: Elaboração própria (2026).

A Figura 1 ilustra, de forma simplificada, o percurso que uma pergunta percorre no sistema avaliado: consulta, recuperação (densa, esparsa ou por grafo), geração da resposta a partir da evidência recuperada e, na condição verificada, uma etapa adicional de auditoria antes da

resposta final. É apenas um esquema de trabalho desta fase do projeto; o diagrama definitivo será redesenhado quando a arquitetura estiver congelada.

Citação direta com mais de 3 linhas — recuo de 4 cm, fonte 10, espaçamento simples e sem aspas, no idioma original do texto fonte:

Assim, segundo Lewis et al., sintetizando a motivação original do RAG:

Large pre-trained language models have been shown to store factual knowledge in their parameters, and achieve state-of-the-art results when fine-tuned on downstream NLP tasks. However, their ability to access and precisely manipulate knowledge is still limited, and hence on knowledge-intensive tasks, their performance lags behind task-specific architectures. (LEWIS *et al.*, 2020)

Citação indireta — texto baseado na obra consultada, com a ideia transcrita em palavras próprias:

Para Edge *et al.* (2024), a limitação central do RAG convencional não está na recuperação de um fato isolado, e sim em perguntas “globais”, que pedem uma síntese sobre toda a coleção de documentos; a solução proposta constrói um grafo de conhecimento a partir dos documentos-fonte e pré-gera resumos de comunidades de entidades relacionadas, combinando-os em tempo de consulta para responder a esse tipo de pergunta — com ganhos relatados de abrangência e diversidade da resposta frente a um RAG convencional.

Tabela 1 – Condições de recuperação comparadas neste trabalho

Condição	Índice vetorial	Índice esperso (BM25)	Grafo de conhecimento
RAG denso	Sim	Não	Não
RAG denso-esperso	Sim	Sim	Não
GraphRAG incremental	Sim	Não	Sim

Fonte: Elaboração própria (2026).

A Tabela 1 resume as três condições de recuperação comparadas na fase confirmatória deste trabalho, antes da ampliação exploratória para um número maior de condições.

3 PROCEDIMENTOS METODOLÓGICOS

Este capítulo apresenta como o desenho descrito no referencial teórico foi implementado e avaliado: o tipo e a abordagem da pesquisa, a arquitetura de sistema efetivamente construída, o pipeline de ingestão mantido como constante experimental, o desenho do harness que testa as hipóteses H1 e H2, a curadoria do golden dataset e as métricas de avaliação empregadas.

3.1 Tipo e abordagem da pesquisa

Esta pesquisa é aplicada quanto à natureza: não busca conhecimento pelo conhecimento, mas resolver um problema concreto de recuperação e geração de resposta sobre um corpus jurídico-administrativo real, com resultado destinado a uso direto. Quanto à abordagem, é multimétodos — quantitativa e qualitativa na mesma investigação, seguindo o desenho de Creswell e Plano Clark (CRESWELL; PLANO CLARK, 2018).

3.2 Instrumentos de coleta de dados

Descreva os instrumentos utilizados, o universo e a amostra, os critérios de inclusão e exclusão e o período de coleta.

3.3 Procedimentos de análise

Explique como os dados foram tratados e analisados, indicando as categorias de análise e, quando houver, as ferramentas estatísticas ou de análise de conteúdo empregadas.

4 ANÁLISE E DISCUSSÃO DOS DADOS

Este capítulo apresenta o resultado da execução do harness de avaliação sobre as hipóteses H1 e H2, na mesma ordem em que os objetivos específicos do Capítulo 1 as enunciam, e discute esse resultado à luz do referencial teórico do Capítulo 2. O estudo tem duas fases, deliberadamente mantidas separadas para não misturar teste de hipótese pré-registrado com investigação motivada pelo próprio resultado: uma fase confirmatória, que testa H1 e H2 exatamente como especificadas no Capítulo 3, e uma fase exploratória, posterior e motivada pelo resultado da primeira, conduzida com o mesmo rigor estatístico mas sem status de teste de hipótese.

4.1 Apresentação dos resultados

O método de comparação estatística especificado no desenho metodológico — teste pareado de Wilcoxon signed-rank com correção de Bonferroni — não é só uma escolha teoricamente mais correta que um teste para amostras independentes: é empiricamente mais sensível sobre este dado. Recalculando a comparação mais apertada de H1 (RAG denso-esparso contra RAG denso) com os dois métodos, o teste pareado correto produz um p-valor dez vezes menor que o teste não pareado — evidência de que o pareamento carrega informação real: uma pergunta difícil tende a ser difícil nas três condições de retrieval, e o teste pareado neutraliza essa variação compartilhada em vez de deixá-la diluir a comparação (ver Tabela 1 e Figura 1).

4.2 Discussão

Confronte os resultados com o referencial teórico construído no Capítulo 2. Indique convergências, divergências e possíveis explicações, sempre com o devido suporte bibliográfico.

5 CONSIDERAÇÕES FINAIS

Este trabalho perguntou qual estratégia de recuperação — RAG denso, RAG denso-esparso ou GraphRAG incremental — e qual estratégia de geração — single-pass ou verificada multiagente — produz respostas mais precisas, fundamentadas e rastreáveis sobre um corpus jurídico-administrativo brasileiro. A resposta obtida diverge, em parte, da hipótese que orientou o desenho do estudo: o GraphRAG incremental não supera o RAG denso-esparso com significância estatística em nenhuma das quatro métricas avaliadas, apesar de superar o RAG denso puro nas quatro; a geração verificada multiagente não melhora a fidelidade nem a taxa de verificação de citação em relação à geração single-pass, em nenhuma das duas bases de retrieval testadas.

O objetivo geral — comparar empiricamente estratégias de recuperação e de geração sobre esse corpus — foi perseguido nesta fase do projeto através do desenho descrito no Capítulo 3. Dos objetivos específicos, construir o corpus e o harness de avaliação é uma frente já em andamento; avaliar H1 e H2 depende da execução completa do harness sobre o golden dataset, ainda em curadoria nesta etapa do mestrado.

A formatação deste trabalho segue as normas da ABNT para apresentação de trabalhos acadêmicos (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011), para elaboração de referências (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2018) e para apresentação do sumário (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2012). Note, na lista de referências, que as entradas repetidas do mesmo autor são substituídas por um travessão, conforme exige a NBR 6023.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro, 2011.

_____. **NBR 6027**: informação e documentação: sumário: apresentação. Rio de Janeiro, 2012.

_____. **NBR 6023**: informação e documentação: referências: elaboração. Rio de Janeiro, 2018.

CRESWELL, John W.; PLANO CLARK, Vicki L. **Designing and Conducting Mixed Methods Research**. 3. ed. Los Angeles: Sage Publications, 2018.

EDGE, Darren; TRINH, Ha; CHENG, Newman; BRADLEY, Joshua; CHAO, Alex; MODY, Apurva; TRUITT, Steven; METROPOLITANSKY, Dasha; NESS, Robert Osazuwa; LARSON, Jonathan. **From Local to Global: A Graph RAG Approach to Query-Focused Summarization**. [S. l.], 2024. Disponível em: <https://arxiv.org/abs/2404.16130>. Acesso em: 2 out. 2026.

LEWIS, Patrick; PEREZ, Ethan; PIKTUS, Aleksandra; PETRONI, Fabio; KARPUKHIN, Vladimir; GOYAL, Naman; KÜTTLER, Heinrich; LEWIS, Mike; YIH, Wen-tau; ROCKTÄSCHEL, Tim; RIEDEL, Sebastian; KIELA, Douwe. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *In: ADVANCES in Neural Information Processing Systems 33 (NeurIPS 2020)*. [S. l.: s. n.], 2020. Disponível em: <https://arxiv.org/abs/2005.11401>. Acesso em: 2 out. 2026.

APÊNDICE A – ROTEIRO DE ENTREVISTA SEMIESTRUTURADA

Insira aqui o conteúdo do apêndice: questionários, roteiros, formulários de consentimento, transcrições ou qualquer outro material produzido por você.

APÊNDICE B – TABELAS COMPLEMENTARES

Insira aqui o conteúdo do segundo apêndice. Cada chamada de `\apendice{}` gera automaticamente uma nova página e uma entrada no sumário.

ANEXO A – LEGISLAÇÃO DE REFERÊNCIA

Insira aqui o conteúdo do anexo: cópias de leis, pareceres, laudos, mapas ou qualquer material de terceiros que sustente a argumentação do trabalho.